نمونه سوال برای آمادگی پایانترم

سوال ۱)

در مورد جملات زیر صحیح یا غلط بودنشان را تعیین کنید و برای دلیل آن یک توضیح (مختصر) نیز ارائه دهید.

الف) در یک MDP برای تصمیم گیری در هر لحظه، هیچ نیازی به تاریخچه تصمیمات تا آن لحظه نداریم.

ب) با افزایش مقدار γ در معادله بلمن[2]، تمرکز ما روی رویداد های اخیر بیشتر می‌شود.

ج) اگر مقدار پاداش به ازای عمل a در وضعیت s برابر r باشد و هیچ عمل ممکن دیگری نداشته باشیم (تنها امکان انتخاب a را داریم) مقدار ارزش بهینه[3] آن وضعیت (s) برابر r خواهد بود.

د) به دست آوردن **مقادیر عمل-وضعیت بهینه**[4] برای یک MDP معادل **حل شدن** آن MDP است.

پاسخ :

الف) **صحیح** – این ویژگی مارکو است که مستقل از گذشته است.

ب) **غلط** – با افزایش ضریب افق دید، تمرکز ما روی رویداد های قدیمی تر بیشتر خواهد شد.

ج) **غلط** – مقدار ***value** ربطی به پاداش بلافصل ندارد و باید مطابق فرمول محاسبه شود.

د) **صحیح** – با داشتن ***Q** می توان یک **MDP** را به نحو بهینه طی کرد که معادل حل شدن آن است.

سوال ۲)

فرض کنید می‌خواهیم از روش یادگیری Q تخمینی[18] در یک ماشین خودران برای خودداری از برخورد با عابرین پیاده استفاده کنیم:

الف) شما از کدام ویژگی‌های محیط برای تشکیل تابع ارزش خطی[19] استفاده می‌کنید؟ چرا؟

ب) دو حالت که بر اساس این ویژگی‌ها مشابه هستند اما ارزش بسیار متفاوت دارند را مثال بزنید.

پاسخ:

الف)

ویژگی‌هایی که انتخاب می‌شوند باید بتوانند تا حد امکان موقعیت‌های متفاوت را از یکدگیر تمیز دهند. یک حالت از انتخاب ویژگی‌ها می‌تواند به شکل زیر باشد:

1) موقعیت خودرو

2) سرعت خودرو

3) فاصله خودرو از نزدیک‌ترین جسم

4) سرعت نزدیک شدن به نزدیک‌ترین جسم

5) فاصله خودرو از حاشیه جاده

6) میزان ترافیک جاده

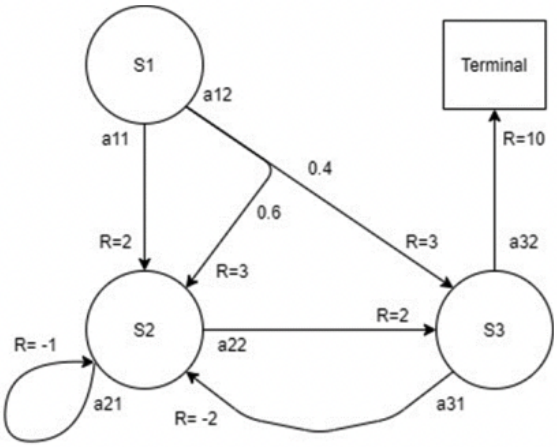
7) میزان بارندگی، رطوبت و یخ زدگی جاده

و .....

ب) حتی اگر تمام این ویژگی‌ها در تابع ارزش خطی مورد استفاده قرار بگیرند و ضرایب نیز به بهترین شکل آموخته شوند، هنوز عامل می‌تواند دچار خطاهای فاحش شود. برای مثال عامل نمی‌تواند یک خودرو که چراغ راهنمای خود را روشن کرده و قصد پیچیدن در جاده دارد را از یک خودروی معمولی تشخیص دهد و همین ممکن است باعث رخ دادن حادثه شود.

سوال ۳)

برای این سوال، MDP زیر را در نظر بگیرید. (مقدار γ را ۰.۵ در نظر بگیرید.)



الف) فرض کنید در ابتدا مقدار ارزش[5] همه وضعیت‌ها (S) صفر است. مقادیر V وضعیت های مختلف را بر اساس فرمول به روز رسانی ارزش (که در زیر آمده است) در **سه** مرحله به روز کنید.

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma V_k(s')\right]$$

ب) آیا انجام این عملیات به تعداد دفعات **متناهی** منجر به **همگرایی** مقادیر V خواهد شد؟ چرا؟

ج) بر اساس مقادیری که در بخش الف به دست آوردید، سیاست را تعیین کنید. این کار به معنی تعیین عمل[6] بهینه به ازای هر وضعیت، با استفاده از فرمول زیر است.

$$\pi\ (s) = \arg\max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V\ (s')]$$

(امتیازی) د) پس از محاسبه سیاست، آن را ارزیابی کنید. یعنی طبق فرمول زیر، مقدار ارزش هر وضعیت را تا زمانی که همگرا شود، تعیین کنید (حداقل ۳ تکرار).

$$V^{\pi}_{k+1}(s) \leftarrow \sum_{s'} T(s,\pi(s),s')[R(s,\pi(s),s') + \gamma V^{\pi}_{k}(s')]$$

پاسخ:

الف) مقدار **Value** همه وضعیت‌ها (**S**) صفر است. مقادیر **V** وضعیت های مختلف را بر اساس فرمول به روز رسانی **value** (که در زیر آمده است) در **سه** مرحله به روز می کنیم.

$$V_{k+1}(s) \leftarrow \max_a \sum_{s'} T(s,a,s') \left[R(s,a,s') + \gamma V_k(s')\right]$$

$$V_0(s_1) = 0, V_0(s_2) = 0, V_0(s_3) = 0$$

$$V_1(s_1) = \max\big([2 + (0.5)(0)], [0.4\big(3 + (0.5)(0)\big) + 0.6\big(3 + (0.5)(0)\big)]\big) = 3$$
$$V_1(s_2) = \max([-1 + (0.5)(0)], [2 + (0.5)(0)]) = 2$$
$$V_1(s_3) = \max([-2 + (0.5)(0)], [10 + (0.5)(0)]) = 10$$

—

$$V_2(s_1) = \max\big([2 + (0.5)(2)], [0.4\big(3 + (0.5)(10)\big) + 0.6\big(3 + (0.5)(2)\big)]\big) = 5.6$$
$$V_2(s_2) = \max([-1 + (0.5)(2)], [2 + (0.5)(10)]) = 7$$
$$V_2(s_3) = \max([-2 + (0.5)(10)], [10 + (0.5)(0)]) = 10$$

—

$$V_3(s_1) = \max\big([2 + (0.5)(7)], [0.4\big(3 + (0.5)(10)\big) + 0.6\big(3 + (0.5)(7)\big)]\big) = 7.1$$
$$V_3(s_2) = \max([-1 + (0.5)(7)], [2 + (0.5)(10)]) = 7$$
$$V_3(s_3) = \max([-2 + (0.5)(10)], [10 + (0.5)(0)]) = 10$$

ب) **بله** همگرا خواهد شد – دلیل آن این است که **MDP** مد نظر عمق محدود دارد و دور هم ندارد و لذا اثبات می شود که با انجام این مراحل به صورت پی در پی در نهایت به مقادیر ثابتی خواهیم رسید. در واقع همین الان هم به نقطه همگرایی رسیدیم.

ج) بر اساس مقادیری که در بخش الف به دست آوردید، سیاست را تعیین می کنیم.

$$\pi\ (s) = \arg\max_a \sum_{s'} T(s,a,s')[R(s,a,s') + \gamma V\ (s')]$$

$$\pi(S_1) = max\ \Big((2 + (0.5)(7)), 0.6\big(3 + (0.5)(7)\big) + 0.4\big(3 + (0.5)(10)\big)\Big)$$
$$\rightarrow \pi(S_1) = \boldsymbol{a12}$$
$$\pi(S_2) = max\ \Big((-1 + (0.5)(7)), \big(2 + (0.5)(10)\big)\Big) \rightarrow \pi(S_2) = \boldsymbol{a22}$$
$$\pi(S_3) = max\ \Big((-2 + (0.5)(7)), (10 + 0)\Big) \rightarrow \pi(S_3) = \boldsymbol{a32}$$

د) طبق فرمول زیر، مقدار value هر وضعیت را تعیین می کنیم. دقت کنید که فقط عملی که سیاست فعلی تعیین می کند را بررسی می کنیم.

$$V_{k+1}^{\pi}(s) \leftarrow \sum_{s'} T(s, \pi(s), s')[R(s, \pi(s), s') + \gamma V_k^{\pi}(s')]$$

$V_0^{\pi}(s_1) = 0, V_0(s_2) = 0, V_0(s_3) = 0$

———

$V_1^{\pi}(s_1) = \big[0.4\big(3 + (0.5)(0)\big)\big] + \big[0.6\big(3 + (0.5)(0)\big)\big] = 3$

$V_1^{\pi}(s_2) = [2 + (0.5)(0)] = 2$

$V_1^{\pi}(s_3) = [10 + (0.5)(0)] = 10$

——

$V_2^{\pi}(s_1) = \big[0.4\big(3 + (0.5)(10)\big) + 0.6\big(3 + (0.5)(2)\big)\big] = 5.6$

$V_2^{\pi}(s_2) = [2 + (0.5)(10)] = 7$

$V_2^{\pi}(s_3) = [10 + (0.5)(0)] = 10$

——

$V_3^{\pi}(s_1) = \big[0.4\big(3 + (0.5)(10)\big) + 0.6\big(3 + (0.5)(7)\big)\big] = 7.1$

$V_3^{\pi}(s_2) = [2 + (0.5)(10)] = 7$

$V_3^{\pi}(s_3) = [10 + (0.5)(0)] = 10$

$V_4^{\pi}(s_1) = \big[0.4\big(3 + (0.5)(0)\big) + 0.6\big(3 + (0.5)(0)\big)\big] = 7.1$

$V_4^{\pi}(s_2) = [2 + (0.5)(10)] = 7$

$V_4^{\pi}(s_3) = [10 + (0.5)(0)] = 10$

همانطور که ملاحظه می شود در مرحله سوم همگرا شد. (همچنین دقت کنید که نتیجه با بخش (ب) نیز یکسان است و این تصادفی نیست چرا که همانطور که گفتیم از سیاست بهینه می توان مقادیر بهینه value را نیز به دست آورد)

سوال ۴)

A	B	C	P
+	-	-	0.2
+	-	+	0.05
+	+	-	0.1
+	+	+	0.2
-	-	-	0.25
-	-	+	0.05
-	+	-	0.1
-	+	+	0.05

با در نظر داشتن جدول توزیع توأم مقابل، به سوالات زیر پاسخ دهید.

الف) رابطه میان توزیع توأم[1] و توزیع حاشیه‌ای[2] چیست؟ این موضوع را با حذف دو متغیر تصادفی دلخواه از توزیع توأم جدول نشان دهید.

ب) احتمالات شرطی[3] زیر را محاسبه کنید.

$P(A+|B+)$ $P(B-|C+)$ $P(A+|B-,C+)$

پاسخ :

الف)

توزیع توام در واقع یک جدول نشات گرفته شده از توزیع حاشیه ای است. با حذف یک یا چند متغیر تصادفی از یک جدول و جمع احتمالات متناظر با آنها می توان به توزیع حاشیه مد نظر رسید. برای مثال در جدول مقابل با حدف متغیر های B و C خواهیم داشت:

A	P
+	0.55
-	0.45

که یک توزیع حاشیه ای برای متغیر تصادفی A است

ب)

$$P(A+|B+)=\frac{P(A+,B+)}{P(B+)}=\frac{0.3}{0.45}=\frac{2}{3}$$

$$P(B-|C+)=\frac{P(B-,C+)}{P(C+)}=\frac{0.1}{0.35}=\frac{2}{7}$$

$$P(A+|B-,C+)=\frac{P(A+,B-,C+)}{P(B-,C+)}=\frac{0.05}{0.1}=\frac{1}{2}$$

سوال ۵)

بر اساس جدول احتمالات توأم زیر، تعیین کنید که آیا متغیر های X و Y از هم دیگر مستقل هستند یا خیر؟

X	Y	P
+	-	0.2
+	+	0.5
-	-	0.1
-	+	0.2

پاسخ:

توزیع حاشیه ای هر کدام از متغیر هارا محاسبه می کنیم:

X	P
+	0.7
-	0.3

Y	P
+	0.7
-	0.3

حال دو جدول حاصل را در هم ضرب می کنیم تا جدول توزیع توام اولیه را ایجاد کنیم:

X	Y	P
+	+	0.49
+	-	0.21
-	+	0.21
-	-	0.09

اگر دو متغیر مستقل می بودند، این جدول باید با جدول اول برابر می بود چرا که برای دو متغیر مستقل داریم:

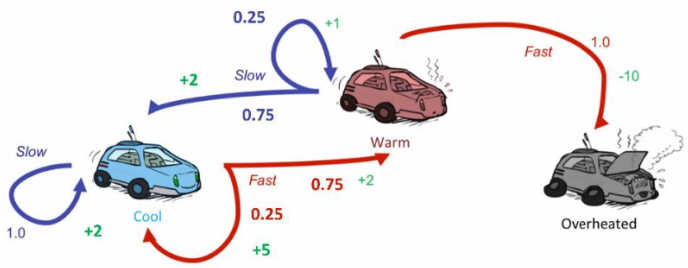
$$P(x, y) = P(x)P(y)$$

سوالات پایانترم گذشته

۲. فرآیند تصمیم گیری مارکوف

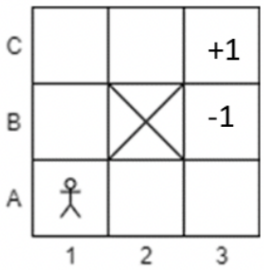
برای دیاگرام زیر الگوریتم value iteration را با فرض طول عمر ۳ انجام داده value را برای هر کدام از حالت‌ها به دست آورید.

فرض: تخفیف نداریم



۳. یادگیری تقویتی

در محیط زیر عامل ابتدا در خانه A1 قرار دارد. حرکاتی که عامل میتواند انجام دهد عبارتاند از N, E, W, S که در هر حرکت عامل پاداشی برابر با ۰.۱- دریافت میکند. همچنین ارزش خانه C3 برابر با ۱ + و ارزش خانه B3 برابر با ۱ – میباشد. هرگاه عامل به یکی از این دو خانه برسد دنباله حرکات به اتمام رسیده و عامل باید مجددا از خانه A1 شروع به حرکت کند. در صورتی که عامل در زمان یادگیری به ترتیب دنباله‌های زیر را تجربه کرده باشد، به سوالات پاسخ دهید.



Episode 1: (A1, N, B1), (B1, N, C1), (C1, E, C2), (C2, E, C3)
Episode 2: (A1, E, A1), (A1, W, A2), (A2, S, A3), (A3, N, B3)
Episode 3: (A1, N, A1), (A1, E, A2), (A2, W, A1), (A1, N, B1), (B1, N, C1), (C1, E, C2), (C2, E, C3)
Episode 4: (A1, E, A2), (A2, E, A2), (A2, E, A3), (A3, N, B3)
Episode 5: (A1, E, A2), (A2, N, A2), (A2, E, A3), (A3, N, A3), (A3, N, B3)
Episode 6: (A1, N, B1), (B1, S, B1), (B1, N, C1), (C1, N, C1), (C1, S, C2), (C2, E, C3)

الف) با فرض تخفیف ۱ تابع ارزش را برای حالت A1 با استفاده از direct evaluation به دست آورید.

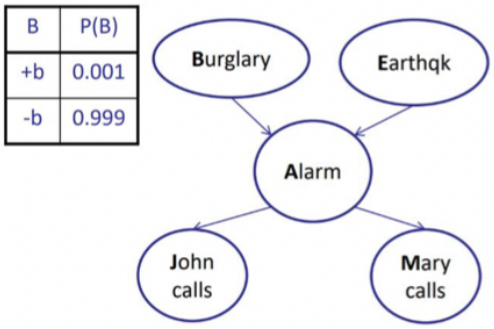
ب) با استفاده از روش temporal difference و با فرض آلفا برابر با ۰.۲۵ تا ارزش Q را برای حالت A1 به دست آورید.

پاسخ :

۴. **شبکه بیزین**

شبکه بیزین زیر را در نظر بگیرید و به سوال الف پاسخ دهید.





B	P(B)
+b	0.001
-b	0.999

E	P(E)
+e	0.002
-e	0.998

A	J	P(J|A)
+a	+j	0.9
+a	-j	0.1
-a	+j	0.05
-a	-j	0.95

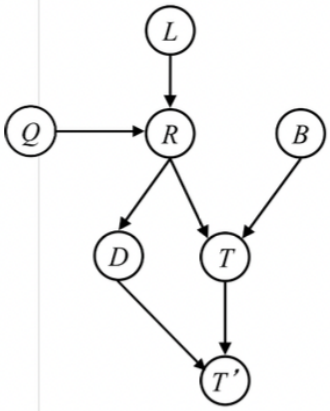
A	M	P(M|A)
+a	+m	0.7
+a	-m	0.3
-a	+m	0.01
-a	-m	0.99

B	E	A	P(A|B,E)
+b	+e	+a	0.95
+b	+e	-a	0.05
+b	-e	+a	0.94
+b	-e	-a	0.06
-b	+e	+a	0.29
-b	+e	-a	0.71
-b	-e	+a	0.001
-b	-e	-a	0.999

الف) با استفاده از روش variable elimination احتمالات زیر را پاسخ دهید:

- **P(M\|b+,e+)**
- **P(A\|b+,e+,j+,m+)**

شبکه بیزین زیر را در نظر بگیرید و به سوال ب پاسخ دهید.



ب) با استفاده از روش d-separation به سوالات زیر پاسخ دهید:

- **L ⫫ T' | T, Q**
- **L ⫫ T' | T, D**
- **Q ⫫ B**
- **Q ⫫ B | T**

سوالات تشریحی

الف) در فرآیندهای تصادفی مارکوف (MDP) می‌توان از دو روش Value Iteration و Policy iteration برای به دست آوردن سیاست بهینه استفاده کرد. نقاط قوت PI در برابر VI چیست؟ شرح دهید.

ب) در یادگیری تقویتی دو روش model-based و model-free را از منظر کاری که انجام میدهند مقایسه کنید و نقاط قوت model-free را در برابر model-based از نظر خود شرح دهید.

ج) اشکال استفاده از Temporal Difference Value Learning چیست؟ راه حل چیست؟

د) تفاوت exploration و exploitation را با ذکر مثال شرح دهید. نقاط ضعف epsilon-greedy را شرح دهید و راه حل ارائه نمایید.

ه) حسن استفاده از approximate q-learning چیست؟ با ذکر مثال شرح دهید.

و) کاربرد الگوریتم d-separation چیست؟ خروجی آن چرا مهم است؟

ز) اشکال استفاده از inference by enumeration با فرض در اختیار داشتن Bayes Net چیست؟ راه حل بهتر چیست و چرا؟

ح) دلیل و حسن استفاده از sampling در Bayes Net چیست؟